

Estimativa de Preço de Imóveis usando Aprendizado Supervisionado: Uma Análise Comparativa de Modelos de Regressão

Resumo

A estimativa de preços de imóveis representa um desafio complexo que intersecta dimensões econômicas, sociais e técnicas. O objetivo deste trabalho é propor e analisar um pipeline de aprendizado supervisionado para a predição de valores imobiliários, comparando a eficácia de modelos lineares regularizados, métodos baseados em árvores e redes neurais. A metodologia envolve a implementação de engenharia de características avançada, integrando variáveis espaciais e socioeconômicas, e a utilização de técnicas de explicabilidade via SHAP (SHapley Additive exPlanations) para mitigar a natureza de "caixa-preta" de modelos complexos. Espera-se que modelos de ensemble, especificamente Gradient Boosting Machines (XGBoost e LightGBM), apresentem a maior acurácia preditiva, enquanto modelos lineares forneçam a base de interpretabilidade necessária para contextos regulatórios.

1. Introdução

A estimativa de preços de imóveis é um problema clássico de regressão com profunda relevância prática. Socialmente, a precisão nessas estimativas influencia diretamente decisões de moradia, a formulação de políticas públicas de habitação e a concessão de crédito imobiliário. A redução de assimetrias de informação entre as partes interessadas (compradores, vendedores e instituições financeiras) promove uma alocação de recursos mais eficiente e justa no mercado urbano.

Do ponto de vista acadêmico, este problema serve como um benchmark para o desenvolvimento de algoritmos de aprendizado de máquina. Ele permite a exploração de técnicas de engenharia de características (feature engineering), a avaliação de métodos de regularização para evitar o overfitting e a investigação de trade-offs entre a performance preditiva e a interpretabilidade do modelo. A ampla disponibilidade de bases de dados públicas, como o conjunto de dados Ames Housing e competições do Kaggle, facilita a replicabilidade dos experimentos e o avanço sistemático do conhecimento na área.

2. Revisão da Literatura (Estado da Arte)

2.1 Modelos Tradicionais e Hedônicos

Historicamente, a avaliação imobiliária baseou-se em modelos econométricos, com destaque para os modelos hedônicos. Esta abordagem decompõe o preço de um imóvel na soma dos valores de seus atributos individuais (ex: número de quartos, localização, metragem). Embora fundamentais para a economia urbana, esses modelos frequentemente falham ao não capturar interações não lineares complexas entre as variáveis.

2.2 Evolução para o Aprendizado de Máquina

Com o incremento do poder computacional, a literatura transitou para modelos de aprendizado supervisionado. - **Modelos Lineares**

Regularizados: Ridge, Lasso e Elastic Net surgiram para lidar com a alta dimensionalidade de dados, penalizando coeficientes excessivos e melhorando a generalização. - **Métodos Baseados em Árvores:** Breiman

(2001) formalizou as Random Forests, introduzindo robustez contra outliers e a capacidade de capturar heterogeneidade nos dados. - **Gradient**

Boosting Machines (GBM): Friedman (2001) propôs o conceito de boosting, que evoluiu para implementações altamente eficientes como XGBoost (Chen & Guestrin, 2016) e LightGBM (Ke et al., 2017). Estes modelos são amplamente reconhecidos por superarem modelos lineares em cenários de relações não lineares. - **Support Vector Regression (SVR):**

Baseada na teoria de Vapnik, a SVR é eficaz em espaços de alta dimensão, buscando a função de regressão que melhor se ajusta aos dados dentro de uma margem de erro aceitável.

2.3 Pesquisas Aplicadas e Benchmarks

Estudos utilizando o dataset Ames Housing demonstram que a combinação de ensembles com pipelines de imputação sofisticada e transformação de variáveis (como a transformação logarítmica do preço) resulta em métricas de erro (RMSE, MAE) significativamente menores do que as abordagens tradicionais.

3. Metodologia Proposta

3.1 Coleta e Pré-processamento de Dados

O pipeline inicia-se com a limpeza rigorosa dos dados: 1. **Tratamento de**

Dados Ausentes: Utilização de imputação baseada na mediana para variáveis numéricas e na moda para categóricas, ou técnicas mais

avancadas como KNN-Imputer. 2. **Análise de Outliers:** Identificação e remoção de registros inconsistentes via análise de dispersão e Z-score. 3.

Transformações: Aplicação de transformação logarítmica na variável alvo (preço) para normalizar a distribuição e reduzir o impacto de imóveis de luxo extremos.

3.2 Engenharia de Características (Feature Engineering)

A criação de variáveis derivadas é crucial para a performance: - **Variáveis Espaciais:** Cálculo de distância para centros comerciais, estações de transporte e áreas verdes via GIS. - **Variáveis Socioeconômicas:** Integração de índices de renda média por bairro e densidade populacional. - **Codificação:** Aplicação de One-Hot Encoding para categorias com baixa cardinalidade e Target Encoding para categorias com alta cardinalidade (ex: bairros).

3.3 Seleção de Modelos e Treinamento

Serão comparados os seguintes algoritmos: - **Baseline:** Regressão Linear Múltipla. - **Regularizados:** Lasso e Ridge. - **Não Lineares:** Random Forest, XGBoost, LightGBM e MLP (Multi-Layer Perceptron).

A otimização de hiperparâmetros será realizada via Bayesian Optimization ou Grid Search com validação cruzada.

3.4 Avaliação de Desempenho

A validação será conduzida via k-fold cross-validation (ou validação temporal, se houver componente de séries temporais). As métricas de avaliação incluirão: - **RMSE (Root Mean Squared Error):** Para penalizar erros maiores. - **MAE (Mean Absolute Error):** Para obter uma medida de erro médio linear. - **R^2 (Coeficiente de Determinação):** Para medir a proporção da variância explicada pelo modelo. - **MAPE (Mean Absolute Percentage Error):** Para análise de erro relativo.

4. Interpretabilidade e Ética

4.1 Explicabilidade via SHAP

Para evitar a "caixa-preta", utilizaremos o framework SHAP (SHapley Additive exPlanations). Isso permitirá: - **Análise Global:** Identificar quais características (ex: localização, área útil) mais influenciam o preço em todo o dataset. - **Análise Local:** Explicar por que um imóvel específico recebeu determinado valor, decompondo a contribuição de cada feature.

4.2 Considerações Éticas e Vieses

A automação de avaliações imobiliárias pode perpetuar desigualdades se utilizar proxies socioeconômicos que reflitam preconceitos históricos. O trabalho prevê a realização de auditorias de viés para garantir que o modelo não penalize injustamente áreas específicas sem justificativa técnica fundamentada.

5. Resultados Esperados e Discussão

Espera-se que os modelos de Gradient Boosting (XGBoost/LightGBM) dominem a acurácia preditiva, especialmente em datasets com alta complexidade de interações. Contudo, a análise via SHAP deve revelar que a "Localização" continua sendo a variável predominante. A discussão abordará a relação entre a complexidade do modelo e a facilidade de auditoria, sugerindo que, para fins fiscais ou judiciais, modelos lineares regularizados podem ser preferíveis apesar do erro ligeiramente maior.

6. Conclusão

A estimativa de preços de imóveis via aprendizado supervisionado permite a transição de avaliações subjetivas para predições baseadas em dados. A integração de engenharia de características espaciais e a utilização de modelos de ensemble representam o estado da arte na área. Este estudo reafirma a importância de combinar performance preditiva com transparência (explicabilidade), garantindo que a tecnologia sirva como ferramenta de apoio à decisão justa e eficiente no mercado imobiliário.

Referências

- Breiman, L. (2001). Random Forests. Machine Learning.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. KDD.
- De Cock, N. C. (2011). Exploratory Data Analysis of Ames Housing Data.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of Statistics.
- Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NIPS.
- Vapnik, V. (1995). The Nature of Statistical Learning Theory. Springer.